

Sistema de inspecao visual automatica

Projeto final de Visao Computacional: classificacao de frutas fresh vs rotten usando pipeline classico com segmentacao, features manuais, classificadores e avaliacao.

1. Problema e dataset

O problema escolhido foi o cenario de frutas frescas versus frutas podres. A tarefa representa uma inspecao visual binaria: itens dentro do padrao sao classificados como fresh, e itens fora do padrao visual sao classificados como rotten. A escolha e adequada para um pipeline classico porque mudancas de deterioracao costumam aparecer em cor, brilho, textura e formato.

Split	Classe	Imagens
test	fresh	40
test	rotten	40
train	fresh	80
train	rotten	80
val	fresh	20
val	rotten	20




Figura 1. Exemplos do dataset processado nas classes fresh e rotten.

2. Pipeline proposto

O pipeline separa as etapas de preparacao, segmentacao, extracao de atributos, analise de features, classificacao e avaliacao. Essa organizacao permite reproduzir cada etapa e discutir onde os acertos e falhas acontecem.

Pipeline de inspecao visual automatica

Classificacao fresh vs rotten com segmentacao, features manuais e modelos classicos



Saídas geradas: X.csv, y.csv, graficos de features, matrizes de confusao, curvas ROC, exemplos de erros e XAI.

Decisao da rodada demonstrativa: Random Forest por melhor F1 macro no teste e boa interpretabilidade.

Figura 2. Diagrama de blocos do pipeline classico implementado.

3. Segmentacao ou isolamento do objeto

Foram comparados dois metodos: limiarizacao em HSV e limiarizacao por Otsu. O HSV foi usado como metodo principal para extracao de features por lidar melhor com diferencas de cor e fundo no subconjunto analisado. Otsu foi mantido como comparacao visual para documentar acertos e falhas.




Figura 3. Exemplo de comparacao entre segmentacao HSV e Otsu.

4. Features extraídas

O vetor de entrada combina famílias de features vistas em aula: forma, momentos de Hu, cor e textura. As features de forma resumem area, perimetro, circularidade, eccentricidade, solidez e extent. Os momentos de Hu capturam propriedades inerciais da mascara. As features de cor usam medias e desvios em RGB e HSV. As features de textura usam GLCM e LBP.

Familia	Exemplos	Justificativa
Forma	area, perimetro, circularidade	Defeitos e recortes podem alterar contorno.
Hu	hu_1 a hu_7	Resumo invariante da geometria da mascara.
Cor	RGB/HSV media e desvio	Podridao altera brilho, saturacao e tonalidade.
Textura	GLCM, LBP	Manchas e enrugamento mudam padroes locais.

5. Selecao e analise de features

O SelectKBest destacou textura e cor como principais familias discriminativas.

Feature	Score
glcm_homogeneity	88.34
hsv_v_mean	62.18
rgb_r_mean	51.65
hsv_s_mean	48.57
lbp_bin_2	32.87
glcm_correlation	24.40
rgb_g_mean	18.78
glcm_energy	17.04




Figura 4. Boxplots das features por classe.

Analise visual complementar

A matriz de correlacao ajuda a identificar redundancias entre atributos, enquanto o PCA oferece uma visao compacta da separacao entre classes. Esses graficos nao substituem a avaliacao supervisionada, mas apoiam a interpretacao do comportamento do vetor de features.




Figura 5. Correlacao entre features.




Figura 6. Visualizacao PCA do conjunto de features.

6. Classificadores usados

Foram comparados tres modelos classicos sobre a mesma tabela de features: Regressao Logistica como baseline linear, SVM com kernel RBF para fronteira nao linear e Random Forest para capturar interacoes entre atributos e permitir interpretabilidade por importancia de variaveis.

Modelo	Acuracia	F1 macro	Precisao rotten	Recall rotten	F1 rotten
logistic_regression	80.0%	80.0%	81.6%	77.5%	79.5%
svm_rbf	81.2%	81.2%	82.1%	80.0%	81.0%
random_forest	82.5%	82.5%	84.2%	80.0%	82.1%




Figura 7. Comparacao de metricas entre os classificadores.

7. Resultados e metricas

O melhor resultado no teste foi obtido pelo Random Forest, com acuracia de 82,5%, F1 macro de 82,5% e F1 da classe rotten de 82,1%. Como a classe rotten representa defeito, o recall dessa classe tambem foi observado; Random Forest e SVM atingiram 80,0% nessa metrica.




Figura 8. Matriz de confusao normalizada do Random Forest.




Figura 9. Curva ROC do Random Forest para a classe rotten.

8. Analise de erros

A analise de erros mostra falsos positivos e falsos negativos. Falsos positivos ocorreram em frutas frescas com brilho, textura natural intensa, sombras ou fundo residual. Falsos negativos ocorreram em frutas podres quando a deterioracao era localizada, quando a cor global ainda era semelhante a frutas aceitaveis ou quando fundo/rotacao afetaram a mascara.



Figura 10. Dez exemplos de erro do Random Forest com rotulo real e predito.

Tipo	Hipotese resumida
Fresh -> rotten	Textura de casca, sombras, brilho e tons escuros podem parecer deterioracao.
Rotten -> fresh	Defeito localizado ou cor global ainda aceitavel pode mascarar sinais de podridao.
Segmentacao	Bordas pretas, fundo residual e rotacao alteram forma, cor e textura.

9. Conclusao e limitacoes

Para a rodada demonstrativa, o modelo recomendado para producao seria o Random Forest. Ele apresentou o melhor F1 macro no teste, manteve recall competitivo para a classe rotten e permite explicacao por permutation importance. Mesmo assim, a solucao ainda tem limitacoes: depende da qualidade da segmentacao, usa estatisticas globais que podem diluir defeitos pequenos e foi avaliada em uma amostra controlada do dataset.

10. Bonus e nivel avancado

Como bonus, foi implementada explicabilidade por permutation importance e uma interface Streamlit para explorar metricas, figuras, matrizes, erros e XAI. As principais features por permutation importance reforcam a coerencia tecnica: saturacao, textura LBP e canais de cor aparecem entre os atributos mais influentes.

Feature	Importancia media
hsv_s_mean	0.0439
lbp_bin_2	0.0249
rgb_r_mean	0.0113
lbp_bin_6	0.0112
rgb_b_std	0.0101
hsv_v_std	0.0087
glcm_homogeneity	0.0080
lbp_bin_9	0.0062




Figura 11. Permutation importance do Random Forest.

Referencias de execucao e reprodutibilidade

O repositório contém notebooks, scripts e módulos organizados por etapa. O pipeline principal pode ser reproduzido pelos comandos do README. As principais saídas são X.csv, y.csv, manifest.csv, gráficos de segmentação, gráficos de features, métricas, matrizes de confusão, curvas ROC, exemplos de erros e dashboard Streamlit.

Artefato	Papel
X.csv / y.csv	Tabela de features e rotulos.
src/	Implementacao reutilizavel de dataset, segmentacao, features, analise e modelos.
scripts/	Execucao reprodutivel de cada etapa.
outputs/	Figuras, metricas e evidencias usadas no relatorio.
dashboard_app.py	Interface Streamlit para apresentacao dos resultados.